СПРАВОЧНИК · АРТУР ХАНТ

Свой ИИ на компьютере или облачный сервис: путеводитель

Что поручить ИИ в офисной работе, какие сервисы доступны в России, какие данные нельзя отдавать в облако, какое оборудование купить и сколько это стоит · цены оборудования — на 26.10.2026, сведения о России — на 09.11.2026

Публичная версия **Обновлено 09.11.2026** **Артур Хант — ассистент эксперта**

Содержание

Словарик: термины простыми словами 3

Что поручить ИИ в офисной работе 3

Какие сервисы доступны в России 4

Отдельно для каждой группы читателей 5

Какие данные нельзя отдавать в облако 12

Как выбрать: четыре вопроса 12

Свой ИИ или облачный: сравнение по восьми признакам 13

Быстрый старт: свой ИИ за один вечер 14

Какое оборудование нужно и сколько оно стоит (октябрь 2026) 15

Аренда вместо покупки: облако и дата-центры 17

Как быстро устаревает оборудование 18

Готовый план для типичного случая 19

Частые вопросы 20

Об этом документе

Путеводитель для офисного работника и руководителя небольшой команды: что поручить искусственному интеллекту в обычной офисной работе, какие сервисы доступны в России, какие данные нельзя отдавать в облако, как за вечер запустить свой ИИ на компьютере, какое оборудование нужно для отдела и компании и сколько оно стоит — в России и для сравнения в США, Германии, Китае и Индии. Путеводитель написан для семи групп читателей: офисных работников — экономистов, юристов, руководителей и инженеров, в том числе в крупных промышленных и нефтегазовых компаниях; IT-специалистов; фрилансеров и удалённых специалистов; школьников 9–11 классов; студентов; учителей и преподавателей вузов; врачей и медсестёр. У каждой группы есть свой раздел.

Как пользоваться. Начните с раздела «Что поручить ИИ» и правил о данных — они нужны всем. Потом — четыре вопроса для выбора, сравнение и, если решили запускать свой ИИ, — быстрый старт, оборудование и цены. Цены оборудования — на 26 октября 2026 года, сведения о российских сервисах и правилах — на 9 ноября 2026 года.

Словарик: термины простыми словами

Облачная (централизованная) модель

ИИ, который работает на серверах компании: ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT. Вы пишете вопрос на сайте или в приложении, а ответ считается у них.

Локальная модель

ИИ, который вы скачиваете и запускаете на своём компьютере или сервере. Интернет для работы не нужен, данные никуда не уходят.

Открытые веса (open-weight)

модели, которые разработчики разрешают скачать: Qwen, DeepSeek, Llama, Gemma, GigaChat Lite.

B (миллиарды параметров)

размер модели: 7B — 7 миллиардов «настроек». Чем больше, тем умнее модель и тем мощнее нужен компьютер.

4-bit, 8-bit

сжатие модели (квантование): 4-bit занимает примерно вчетверо меньше памяти, чем исходная модель, почти без потери качества.

MoE

модель «из экспертов»: в каждый момент работает только её часть, поэтому большая модель считает быстрее.

Видеокарта (GPU) и видеопамять

главная деталь для ИИ. Объём видеопамяти (24, 32, 96 ГБ) определяет, какого размера модель поместится. У Mac с чипом Apple память общая (unified memory) — её можно почти всю отдать модели.

Токен

кусочек текста примерно в 3–4 буквы. Облачные сервисы считают оплату в токенах.

т/с (токенов в секунду)

скорость, с которой модель пишет ответ. 85 т/с — быстрее, чем человек читает.

RAG

поиск по своим документам: модель отвечает, опираясь на ваши файлы.

CapEx

разовые затраты на покупку оборудования (в отличие от ежемесячной подписки).

Лакх и крор

индийские единицы счёта: 1 лакх = 100 000 рупий, 1 крор = 10 000 000 рупий.

ЦОД

центр обработки данных — здание с серверами провайдера.

Колокация (colocation)

вы ставите свой сервер в чужой ЦОД и платите за место, электричество и интернет.

Ollama, LM Studio, vLLM, Open WebUI

программы для запуска локальных моделей: первые две — для себя на компьютере, вторые — для сервера на команду.

Что поручить ИИ в офисной работе

Задача	Где запускать	Какая модель подойдёт
Письма, ответы клиентам, служебные записки	Облако — если в тексте нет персональных данных и тайн; иначе своя модель	Любая современная модель; для русского языка хорошо подходят GigaChat и Алиса AI

Задача	Где запускать	Какая модель подойдёт
Протоколы встреч и расшифровка записей	Своя модель, если на записи обсуждают клиентов, деньги, сотрудников	Модели распознавания речи плюс модель 14–30B для пересказа
Договоры, претензии, юридические документы	Своя модель: документы почти всегда содержат персональные данные и условия сделок	Модель 30B и больше; обязательно проверка юристом
Таблицы, формулы, отчёты	Облако — для обезличенных данных; своя модель — для реальных цифр компании	Модели, которые умеют писать формулы и код
Поиск по внутренним документам компании	Своя модель с поиском по документам (RAG)	Модель 14–70B плюс поисковая база по вашим файлам
Презентации, идеи, тексты для соцсетей	Облако — данные публичные	Любая модель; облачные сильнее в креативе и картинках
Обучение и разбор новой темы	Облако — удобнее искать по интернету с источниками	Модели с поиском в интернете
Перевод писем, статей, технической документации	Облако — для публичных текстов; своя модель — для контрактов и внутренней переписки	Модели от 14B хорошо переводят с английского и китайского; термины сверяйте с глоссарием компании
Проверка текста: ошибки, стиль, сокращение	Облако — если в тексте нет тайн; иначе своя модель	Любая модель от 7–8B

Как поставить задачу, чтобы ответ был полезным

1. **Роль и цель.** Скажите, кем модель должна «быть» и что нужно получить: «Ты — юрист компании-покупателя. Найди в договоре поставки условия, невыгодные покупателю».
2. **Исходные данные.** Вставьте текст целиком и задайте рамки: «Отвечай только по тексту договора. Если ответа в тексте нет — так и напиши».
3. **Формат ответа.** Опишите, как должен выглядеть результат: «таблица: пункт договора — риск — как переформулировать» или «письмо на 5–7 предложений, деловой тон, без канцелярита».
4. **Проверка.** Попросите указывать номер пункта или страницу для каждого вывода и сверяйте сами. Модель может уверенно ошибаться в цифрах, датах и ссылках на законы.

Типичная ошибка — отдать ИИ всю задачу целиком и не проверить результат. Лучше делить работу на шаги: сначала пересказ документа, потом список рисков, потом черновик письма, — и проверять каждый шаг. Так ошибку видно сразу, а не в готовом документе.

Какие сервисы доступны в России

Сервис	Как получить доступ	Цена	Что важно
GigaChat (Сбер)	Бесплатный доступ для физлиц через Сбер ID (по данным обзоров — пакет токенов на год); для компаний — платный доступ по API и в облаке	API: от 0,065 ₽ (Lite) до 0,65 ₽ (Max) за 1000 токенов	Российский провайдер, данные в России; хорош в русском языке и деловых текстах

Сервис	Как получить доступ	Цена	Что важно
Алиса AI и YandexGPT (Яндекс)	Бесплатный базовый доступ к Алисе AI; расширенные функции — с подписками Яндекса; для компаний — Yandex AI Studio	API: YandexGPT Lite — около 0,2 ₽, YandexGPT Pro — около 0,8 ₽ за 1000 токенов (с НДС)	Российский провайдер, интеграция с сервисами Яндекса и поиском
Российские облака с готовыми моделями	Yandex Cloud, Cloud.ru, VK Cloud, Selectel — серверы с видеокартами и модели «под ключ»	По договору с юрлицом; см. раздел «Аренда вместо покупки»	Подходит компаниям: договор, оплата в рублях, ЦОД в России
Зарубежные сервисы (ChatGPT, Claude, Gemini и др.)	Официально не поддерживают пользователей из России; карты российских банков к оплате не принимаются	Подписка $20–200 в месяц у самих сервисов	Риск блокировки аккаунта и трансграничной передачи данных — см. раздел о данных

Цены российских сервисов — по открытым обзорам тарифов на октябрь — ноябрь 2026 года; они расходятся между источниками. Проверяйте на официальных страницах (developers.sber.ru, aistudio.yandex.ru).

Бесплатные лимиты и тарифы (ноябрь 2026)

1. **GigaChat API для физлиц — бесплатно на год.** Даётся 365 млн токенов на 12 месяцев: 250 млн — модель Lite, 40 млн — Pro, 25 млн — Max, 50 млн — Ultra; ответы генерируются в один поток. Если не хватит — платные пакеты на месяц, например 20 млн токенов Lite за 1 300 ₽ (тарифы Сбера от 07.10.2026).
2. **GigaChat для компаний и ИП.** Оплата по факту: Lite — 0,065 ₽, Pro — 0,5 ₽, Max — 0,65 ₽ за 1000 токенов с НДС; минимальный платёж — 600 ₽ в месяц, если сервисом пользовались. С 1 сентября 2026 года новые клиенты оплачивают модели через платформу cloud.ru.
3. **Yandex AI Studio: не только модели Яндекса.** Кроме Alice AI LLM (0,5 ₽ за 1000 входящих и 1,2 ₽ за 1000 исходящих токенов) и облегчённой Alice AI LLM Flash (0,1 и 0,2 ₽) там можно подключить открытые модели: DeepSeek V4 Flash (0,3 и 0,5 ₽), Qwen3.6 35B (0,2 и 0,3 ₽), gpt-oss-120b (0,3 ₽).
4. **Стартовый грант Yandex Cloud.** Новым пользователям начисляют 4 000 ₽ (физлицам) или 10 000 ₽ (юрлицам) на 60 дней — этого хватает, чтобы бесплатно проверить модели на своих задачах.

Сколько это стоит на практике. Деловое письмо с исходными материалами — примерно 1 000 токенов на входе и 500 на выходе. В GigaChat Lite такое письмо обойдётся примерно в 0,1 ₽, в GigaChat Max — около 1 ₽, в YandexGPT Pro 5.1 — около 1,2 ₽. Даже 1 000 писем в месяц на самой дорогой из этих моделей — около 1 000–1 200 ₽.

Отдельно для каждой группы читателей

Дальше — по странице на каждую группу читателей: что важно именно вам и с чего начать. Найдите свою карточку; остальные разделы документа общие для всех.

В этом разделе — по странице на каждый пункт:

1. Экономистам, юристам, руководителям и инженерам
2. IT-специалистам
3. Фрилансерам и удалённым специалистам
4. Школьникам 9–11 классов и студентам
5. Учителям и преподавателям вузов
6. Врачам и медсёстрам

Экономистам, юристам, руководителям и инженерам

Экономисты, финансисты, юристы, руководители и топ-менеджеры, инженеры крупных промышленных и нефтегазовых компаний

30-60%
дороже техника в России, чем в США

1-3 месяца
пилота в аренду до покупки сервера

Офлайн
локальная модель работает без интернета

Что важно знать

Экономистам

Локальная модель на рабочем ноутбуке подойдёт для пересказа отчётов и подготовки комментариев к цифрам, не отправляя данные компании наружу.

Юристам

Анализ договоров и документов клиентов – классическая задача для локальной модели на 30 миллиардов параметров и больше: юридическая тайна остаётся на вашем компьютере. Итог всегда проверяет юрист.

Руководителям

Для пилота не нужно сразу покупать сервер за миллионы: начните с аренды у российского облачного провайдера на 1-3 месяца, измерьте пользу и только потом решайте о покупке (таблицы раздела «Аренда вместо покупки»).

Инженерам промышленных и нефтегазовых компаний

Поиск по нормативам, регламентам и технической документации – сильная сторона локальной модели с поиском по документам (RAG). Она работает без интернета, что важно на удалённых месторождениях и объектах с ограниченной связью и для объектов КИИ.

Делайте

- Начните с 3-5 задач отдела из таблицы «Что поручить ИИ»
- Секретные документы – в локальную модель
- Посчитайте аренду и покупку до решения

Не делайте

- Не покупайте сервер до пилота
- Не отправляйте договоры и техдокументацию в облако
- Не доверяйте итогам модели без проверки специалистом

Инструкция: с чего начать

1. Выпишите 3-5 задач отдела, где ИИ сэкономит больше всего времени (таблица «Что поручить ИИ»).
2. Разделите их на облачные (без тайн) и локальные (с тайнами).
3. Для пилота в отделе посчитайте аренду на 1-3 месяца и сравните с покупкой сервера.

Где читать подробнее в этом документе

Что поручить ИИ в офисной работе | Аренда вместо покупки | Готовый план для типичного случая

IT-специалистам

Разработчики, системные администраторы, тестировщики, аналитики, специалисты техподдержки

Видеопамять
определяет размер модели

1-2 карты по 48-96 ГБ
для 20-50 пользователей

1-2 дня
развернуть vLLM и Open WebUI

Что важно знать

Типовой стек для компании

vLLM или Ollama для запуска модели, Open WebUI как интерфейс, поиск по документам (RAG) на базе векторной базы, единый вход через корпоративный каталог пользователей.

Как оценить сервер

Объём видеопамяти определяет размер модели, а пропускная способность памяти – скорость. Для 20-50 пользователей обычно хватает одной-двух видеокарт по 48-96 ГБ с моделью 30-70B в сжатии.

Безопасность

Не открывайте интерфейс модели в интернет без авторизации, ведите журналы запросов, обновляйте модели и программы, ограничьте доступ к документам по ролям.

Карьера

Развёртывание и сопровождение языковых моделей (MLOps) – быстро растущее направление; опыт с локальными моделями ценится в банках, промышленности и госсекторе, где облако запрещено.

Делайте

- Начните с Ollama и Open WebUI на своём компьютере
- Добавьте авторизацию и журналы запросов
- Разграничьте доступ к документам по ролям

Не делайте

- Не открывайте интерфейс модели в интернет без входа
- Не обещайте качество облачных моделей
- Не забывайте обновлять модели и программы

Инструкция: с чего начать

1. Поднимите на своём компьютере Ollama и Open WebUI и замерьте скорость на 2-3 моделях.
2. Оцените нагрузку: число пользователей, длина документов, нужен ли поиск по документам (RAG).
3. Подготовьте руководству расчёт: аренда, сервер в офисе или колокация (разделы «Оборудование» и «Аренда»).

Где читать подробнее в этом документе

Какое оборудование нужно и сколько оно стоит | Аренда вместо покупки | Как быстро устаревает оборудование

Фрилансерам и удалённым специалистам

Фрилансеры, digital-специалисты, удалённые сотрудники

32-64 ГБ
памяти – комфортный ноутбук для локальной модели

NDA
соблюдается: данные не уходят из компьютера

$20-200
в месяц – подписки, которые можно заменить

Что важно знать

Документы клиентов под NDA

Локальная модель решает главную проблему фрилансера: можно работать с материалами заказчика, не нарушая соглашение о неразглашении.

Какой компьютер

Ноутбук с чипом Apple и памятью 32-64 ГБ или ПК с видеокартой на 16-24 ГБ – достаточный рабочий инструмент; окупается за счёт экономии на подписках и сохранённых заказов.

Работа без интернета

В поездках и при плохой связи локальная модель продолжает работать.

Оплата облачных сервисов

Из России зарубежные подписки картой российского банка не оплатить; российские сервисы и локальные модели снимают этот вопрос.

Делайте

- Поставьте LM Studio и модель на 14-30 миллиардов параметров
- Работайте с документами клиентов офлайн
- Сравните стоимость подписок и покупки

Не делайте

- Не загружайте материалы под NDA в облако
- Не берите ноутбук с 8 ГБ памяти для работы с ИИ
- Не полагайтесь на зарубежные подписки – оплата из России недоступна

Инструкция: с чего начать

1. Проверьте, сколько памяти у вашего ноутбука, и подберите модель по размеру (раздел «Быстрый старт»).
2. Перенесите работу с материалами клиентов под NDA в локальную модель.
3. Подсчитайте, сколько стоят ваши подписки на облачные сервисы, и сравните с покупкой компьютера.

Где читать подробнее в этом документе

Быстрый старт: свой ИИ за один вечер | **Как покупать в России**

Какие сервисы доступны в России

Школьникам 9–11 классов и студентам

Школьники 9–11 классов и студенты вузов

0 ₽
на старт: бесплатные сервисы и свой ноутбук

16 ГБ
памяти достаточно для модели на 7 миллиардов параметров

RAG
по конспектам – готовый проект для студента ИТ

Что важно знать

Ничего покупать не нужно

Для учёбы хватит бесплатных российских сервисов (GigaChat, Алиса AI) и локальной модели на обычном ноутбуке с 16 ГБ памяти – через LM Studio.

Как использовать для учёбы

Попросите объяснить тему другими словами, придумать задачи для самопроверки, проверить ход решения, потренировать английский. Локальная модель работает без интернета – удобно в дороге и в общежитии.

Не доверяйте вслепую

Модели ошибаются в фактах, датах и вычислениях. Проверяйте по учебнику и конспекту – особенно перед ОГЭ, ЕГЭ и сессией.

Правила школы и вуза

Сдавать сгенерированный текст как свой нельзя; многие вузы требуют помечать использование ИИ (подробнее – в шпаргалке «Приватность ChatGPT»).

Студентам ИТ-направлений

Опыт запуска локальных моделей, поиска по документам (RAG) и веб-интерфейса Open WebUI – хороший проект для курсовой и строчка в резюме для стажировки.

Компьютерные классы и лаборатории

Если своего мощного компьютера нет, спросите на кафедре: во многих вузах есть компьютеры с видеокартами для учебных проектов.

Делайте

- Просите объяснить тему и придумать задачи
- Проверяйте ответы по учебнику
- Студентам ИТ – сделайте проект с локальной моделью

Не делайте

- Не покупайте дорогое оборудование для учёбы
- Не сдавайте ответы модели как свои
- Не готовьтесь к экзамену только по ответам ИИ

Инструкция: с чего начать

1. Установите LM Studio и модель на 7 миллиардов параметров на свой ноутбук.
2. Попросите её объяснить тему из учебника и сверьте ответ с учебником.
3. Студентам ИТ – превратите это в проект: поиск по своим конспектам (RAG).

Где читать подробнее в этом документе

Быстрый старт: свой ИИ за один вечер | Какие сервисы доступны в России | Частые вопросы

Учителям и преподавателям вузов

Учителя школ, преподаватели колледжей и вузов

Локально
всё, где есть данные учеников

1 ноутбук
уже учебный стенд для кружка

7–14B
достаточно модели для уроков

Что важно знать

Локальная модель – для работы с данными учеников
Анализ оценок, черновики характеристик, разбор ответов учеников – всё, где есть персональные данные, – делайте в локальной модели на своём компьютере, без интернета.

Облачные сервисы – для материалов
Планы уроков, задания, вопросы к лекции, объяснения темы разными способами – без имён учеников и студентов.

Школьный и вузовский компьютер
Установку программ согласуйте с администратором: в учебных заведениях часто действуют требования к программному обеспечению.

Для кружка или курса
Один ноутбук с LM Studio и моделью на 7–14 миллиардов параметров – уже учебный стенд: можно показать ученикам, как работает ИИ и почему он ошибается.

Делайте

- Согласуйте установку с администратором
- Показывайте ученикам, где ИИ ошибается
- Материалы уроков готовьте в облаке без имён

Не делайте

- Не обрабатывайте оценки и характеристики в облаке
- Не ставьте программы без разрешения на школьные компьютеры
- Не выдавайте ответ модели за истину

Инструкция: с чего начать

1. Поставьте локальную модель на рабочий компьютер (согласовав с администратором).
2. Обрабатывайте в ней всё, где есть данные учеников; облачные сервисы – только для материалов уроков.
3. Покажите ученикам на уроке, как ИИ ошибается, – это лучшая прививка от слепого доверия.

Где читать подробнее в этом документе

Быстрый старт: свой ИИ за один вечер | **Какие данные нельзя отдавать в облако**

Что поручить ИИ в офисной работе

Врачам и медсёстрам

Врачи, медсёстры и другие медицинские работники

Врачебная тайна
данные пациентов – никогда в публичное облако

Внутри организации
размещение ИИ для медицинских данных

Диагноз
ставит врач, а не модель

Что важно знать

Данные пациентов – никогда в публичное облако

Сведения о здоровье составляют врачебную тайну и особую категорию персональных данных.

Если клиника хочет ИИ для медицинских данных

– только размещение внутри организации или у российского провайдера по договору, с выполнением требований к защите информации в медицинских информационных системах. Решение принимает руководство вместе с ИТ-службой и специалистом по защите информации.

Для себя

локальная модель подойдёт, чтобы пересказать клиническую рекомендацию, перевести статью, подготовить памятку – без данных конкретных пациентов.

Диагноз и лечение

– только врач и зарегистрированные медицинские изделия. Общая языковая модель может ошибаться уверенно и правдоподобно.

Делайте

- Переводите статьи и пересказывайте рекомендации локально
- Привлекайте специалиста по защите информации к внедрению
- Проверяйте ответы по клиническим рекомендациям

Не делайте

- Не загружайте выписки и снимки в облачные сервисы
- Не используйте модель для назначения лечения
- Не внедряйте сервис без ИТ-службы клиники

Инструкция: с чего начать

1. Для себя – локальная модель для перевода статей и пересказа клинических рекомендаций.
2. Данные пациентов – только в системах, одобренных медицинской организацией.
3. Если клиника думает о внедрении ИИ, начните разговор со специалистом по защите информации, а не с покупки сервиса.

Где читать подробнее в этом документе

Какие данные нельзя отдавать в облако | **Аренда вместо покупки**

Быстрый старт: свой ИИ за один вечер

Какие данные нельзя отдавать в облако

1. **Персональные данные — только с осторожностью.** ФИО, телефоны, адреса, паспортные данные, сведения о здоровье и зарплате клиентов и сотрудников защищает закон № 152-ФЗ. Если такие данные попадают в сервис, серверы которого за рубежом, это может считаться трансграничной передачей: до неё компания обязана уведомить Роскомнадзор и иметь законное основание. В июле 2026 года правила такой передачи ужесточили.
2. **Коммерческая и банковская тайна.** Условия договоров, цены, планы, финансовые показатели, сведения о счетах клиентов нельзя отправлять во внешние сервисы без разрешения компании.
3. **Правило компании важнее удобства.** Узнайте, есть ли у вас внутренний регламент об ИИ: какие сервисы разрешены и для каких данных. Если регламента нет — предложите его ввести.
4. **Простое правило для себя.** Если вы не готовы переслать этот текст незнакомому человеку по почте — не отправляйте его в облачный ИИ. Обезличьте данные (уберите имена, номера, суммы) или используйте свою локальную модель.
5. **Настройки приватности.** В облачных сервисах отключите использование ваших диалогов для обучения моделей, если такая настройка есть, и регулярно удаляйте историю.

Какие данные	В облачный сервис	Как поступить
Внутренние регламенты и инструкции без персональных данных	По правилам компании	Российский сервис по договору или своя модель
ФИО, телефоны, адреса, паспорта клиентов и сотрудников	Нет без законного основания	Обезличить или работать в своей модели
Сведения о здоровье, биометрия (особые категории)	Нет	Только своя модель или система клиники с выполненными требованиями защиты
Договоры, цены, финансовая отчётность до публикации	Нет без разрешения компании	Своя модель
Пароли, ключи доступа, токены	Никогда	Удалите их из текста и кода перед любой отправкой

Чем рискует компания. С 30 мая 2025 года за утечки персональных данных организации штрафуют по ст. 13.11 КоАП: утечка данных 1 000 человек и больше — 3–5 млн ₽; 10 000 и больше — 5–10 млн ₽; больше 100 000 — 10–15 млн ₽; особых категорий — 10–15 млн ₽; биометрии — 15–20 млн ₽; повторная утечка — 1–3 % годовой выручки (не меньше 20–25 млн и не больше 500 млн ₽). Не сообщить об утечке — ещё 1–3 млн ₽. Загрузка клиентской базы в непроверенный сервис — один из путей к такой утечке.

Как обезличить: пример. Было: «Иванов Пётр Сергеевич, ООО «Север», договор № 15/24 на 4,2 млн ₽, тел. +7 912 …». Стало: «Клиент А, Компания Б, договор № Х на сумму N». Попросите ИИ составить письмо или найти риски, а настоящие имена и суммы подставьте сами уже в готовый текст. Таблицу «настоящее имя — замена» храните только у себя.

Как выбрать: четыре вопроса

1. **Насколько секретны данные?** Личные, финансовые, юридические и клиентские данные лучше обрабатывать локально — они не покинут ваш компьютер. Публичные и учебные задачи можно решать в облаке.

2. **Нужен ли самый умный ИИ?** Облачные модели сильнее на 6–12 месяцев и умеют искать в интернете с цитатами. Локальные модели 2026 года — на уровне облачных 2024–2025 годов: для большинства офисных задач этого достаточно.

3. **Сколько есть денег и как часто нужен ИИ?** Для старта ничего покупать не нужно: модель запускается на хорошем ноутбуке. Оборудование окупается при постоянной нагрузке; при редкой — дешевле аренда или подписка.

4. **Есть ли время на настройку?** Программы Ollama или LM Studio на ноутбуке ставятся за час. Сервер для команды (vLLM и Open WebUI) — за 1–2 дня и требует навыков.

Ситуация	Что выбрать	Почему
Юрист компании: договоры с персональными данными	Своя модель 30B на ноутбуке с памятью 32–64 ГБ или сервер компании	Тайна и данные клиентов не покидают компанию
Экономист: обезличенные таблицы, задачи раз в неделю	Российский облачный сервис (GigaChat, Алиса AI)	Бесплатно или копейки, без настройки
Отдел 10–20 человек с общей базой регламентов	Сервер в офисе с Open WebUI и поиском по документам или аренда у российского провайдера	Один интерфейс для всех, доступ по ролям
Фрилансер с документами под NDA	Ноутбук с памятью 32–64 ГБ и локальная модель	Не нарушает соглашение и работает в дороге
Школьник или студент	Бесплатные российские сервисы и LM Studio на своём ноутбуке	Ничего не нужно покупать
Клиника, медицинские данные	Только внутри организации или у российского провайдера по договору	Врачебная тайна и требования к медицинским системам

Пример расчёта: облако или своё оборудование. Отдел из 10 человек, каждый делает 50 запросов в день, 22 рабочих дня: 11 000 запросов в месяц. Если на запрос уходит около 1 500 токенов (наше допущение), это 16,5 млн токенов — в GigaChat Max около 10 700 ₽ в месяц. Тихий сервер за 1,3–1,8 млн ₽ при таких тратах окупался бы 10 лет и дольше. Вывод: своё оборудование редко окупается за счёт экономии на токенах — его покупают ради приватности, работы без интернета и независимости от тарифов и правил провайдера.

Свой ИИ или облачный: сравнение по восьми признакам

Что сравниваем	Свой ИИ на компьютере	Облачный сервис (ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT)
Приватность	Данные не покидают ваше устройство или сеть компании. Защищает от провайдера, его сотрудников и от законных запросов к провайдеру.	Данные хранятся у провайдера и выдаются по законным запросам. Срок хранения — от 24 часов до 5 лет, в зависимости от сервиса и настроек.
Качество	Модели с открытыми весами 2026 года — Qwen3.x, DeepSeek V4, Llama 4, Gemma 3, GigaChat Lite — на уровне облачных моделей 2024–2025 годов; отставание 6–12 месяцев.	Самые сильные (фронтирные) модели; работают с картинками, звуком и файлами; ищут в интернете с цитатами; умеют действовать через коннекторы.

Что сравниваем	Свой ИИ на компьютере	Облачный сервис (ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT)
Стоимость	Разовая покупка оборудования — от 150 тыс. до 2,5 млн ₽, плюс электричество 0,3–1,5 кВт. За каждый ответ платить не нужно.	Подписка $20–200 в месяц или $0,3–15 за 1 млн токенов. В России — 0,2–2,7 ₽ за ответ бота.
Доступность из России	Полная. Но видеокарты из-за санкций покупаются через параллельный импорт — на 30–60 % дороже.	Западные сервисы — только через посредников, есть риск блокировки аккаунта; российские — напрямую.
Устаревание	Оборудование экономически устаревает за 2–4 года, физически служит 5–6 лет и дольше. Новые версии моделей выходят примерно раз в квартал — бесплатно.	Провайдер обновляет всё сам, но вы зависите от его тарифов и правил.
Контроль	Полный: вы выбираете версию модели, видите журналы работы, можете работать без интернета.	Нет: модель, лимиты и правила хранения данных меняются без вашего согласия.
Порог входа	Нужны навыки: Ollama или LM Studio — около 1 часа; сервер с vLLM и Open WebUI — 1–2 дня.	Регистрация за 5 минут.
Риски	Кража устройства; ошибки настройки, если открыть доступ из интернета; резервные копии — ваша забота.	Утечки у провайдера; блокировки; смена юрисдикции; подложенные инструкции (prompt injection) через коннекторы.

Гибридный вариант — самый частый на практике. Публичные и обезличенные задачи (идеи, тексты для сайта, разбор новой темы) решают в облачном сервисе, а документы с тайнами и персональными данными — в своей модели. Веб-интерфейс Open WebUI позволяет держать в одном окне и локальные модели, и облачные, подключённые по API: сотрудник выбирает модель под задачу, а администратор может закрыть облачные модели для отделов, где работают с персональными данными.

Быстрый старт: свой ИИ за один вечер

1. **Проверьте компьютер.** Подойдёт ноутбук или ПК с 16 ГБ оперативной памяти и больше; лучше всего — Mac с чипом Apple (M1–M5) или ПК с видеокартой NVIDIA от 8–12 ГБ видеопамяти. Если у вас рабочий компьютер — сначала спросите разрешение у ИТ-отдела.
2. **Установите программу.** Скачайте LM Studio (удобнее для начинающих: окно как у обычного чата) или Ollama с официальных сайтов разработчиков.
3. **Выберите модель.** Для начала — модель на 7–14 миллиардов параметров в сжатии 4-bit (например, Qwen3 или GigaChat с открытыми весами): она займёт 5–10 ГБ и будет работать на обычном ноутбуке. Чем больше памяти, тем больше модель можно взять.
4. **Проверьте на своих задачах.** Дайте модели 3–5 типичных задач: письмо, пересказ протокола, таблицу. Сравните с облачным сервисом на обезличенных данных.
5. **Отключите интернет и убедитесь, что всё работает.** Локальной модели интернет не нужен — так вы будете уверены, что данные не уходят наружу.

Модель	Команда в Ollama	Размер файла	Сколько памяти нужно компьютеру (ориентир)
Qwen3 4B	ollama run qwen3:4b	2,5 ГБ	от 8 ГБ — даже старый ноутбук
Qwen3 8B	ollama run qwen3:8b	5,2 ГБ	от 16 ГБ
Gemma 3 12B (понимает картинки)	ollama run gemma3:12b	8,2 ГБ	от 16 ГБ
Qwen3 14B	ollama run qwen3:14b	9,3 ГБ	от 16–24 ГБ
Gemma 3 27B	ollama run gemma3:27b	17 ГБ	от 32 ГБ
Qwen3 30B-A3B (MoE, быстрая)	ollama run qwen3:30b	19 ГБ	от 32 ГБ

Размеры файлов — по каталогу ollama.com на 10.11.2026. Полезные команды: ollama list — какие модели скачаны, ollama rm qwen3:8b — удалить модель и освободить место.

Если что-то не работает

1. **Модель пишет 1–3 слова в секунду.** Она не помещается в видеопамять и работает на процессоре. Возьмите модель на ступень меньше.
2. **Ответы на смеси языков.** Добавьте в начало запроса: «Отвечай только на русском языке».
3. **Модель «забыла» начало длинного документа.** Делите документ на части по 10–20 страниц и просите пересказ каждой части отдельно.
4. **Компьютер тормозит.** Модель занимает память целиком: закройте лишние программы и вкладки браузера.

Какое оборудование нужно и сколько оно стоит (октябрь 2026)

Чем больше задача и чем больше людей пользуются ИИ, тем мощнее нужно оборудование. Сначала — что купить на каждом уровне и какие модели оно потянет, затем — цены по странам.

Уровень	Что купить	Какие модели потянет	Цена в США
Для себя — ноутбук	MacBook Pro M4 или M5 Pro с памятью 48–64 ГБ или ПК с видеокартой RTX 4090 (24 ГБ)	Модели 7–32B в сжатии 4-bit, например Qwen3 30B-A3B	$2 500–4 000
Для себя или микробизнеса — настольный ПК	Видеокарта RTX 5090 (32 ГБ) и 64–128 ГБ оперативной памяти; сборка $8,5–9 тыс.; одна карта — $4 200–6 000+ (дефицит: их скупают ИИ-компании)	До 70B в сжатии 4-bit; модели MoE на 100B+ — с частичной выгрузкой в обычную память	$8 500–11 000
Малый бизнес — тихий сервер	Mac Studio M5 Ultra с памятью 256–512 ГБ ($5 499–9 499+); подержанный M3 Ultra 512 ГБ — $16,5–27,5 тыс. (снят с продажи в марте 2026)	DeepSeek V4 Flash 284B в 4-bit — около 85 токенов в секунду; модели MoE класса 300B	$9 500–12 000

Уровень	Что купить	Какие модели потянет	Цена в США
Малый и средний бизнес — рабочая станция	Видеокарта RTX PRO 6000 Blackwell 96 ГБ ($8 299), одна или две, или компьютер DGX Spark 128 ГБ (около $4 000–4 700)	Модели 70–120B в сжатии 8-bit; поиск по документам отдела (RAG)	$12 000–25 000
Средний и крупный бизнес — серверная стойка	Сервер с 4–8 ускорителями H100, H200 или B200 — или аренда	Модели 405B и больше, несколько моделей сразу, 100+ пользователей	$250–400 тыс. (8 × H100)

Уровень	США	Германия	Россия	Китай	Индия
Ноутбук	$2 500–4 000	€2 800–4 500	350–550 тыс. ₽	¥18–30 тыс.	₹2,5–4 лакха
Настольный ПК	$8 500–11 000	€9 000–12 000 (карта — от €5 249)	1,0–1,4 млн ₽	¥60–90 тыс. (модель 5090D, ограничения экспорта)	₹8–11 лаккхов
Тихий сервер	$9 500–12 000	€10 000–13 000	1,3–1,8 млн ₽	¥80–100 тыс.	₹10–13 лаккхов
Рабочая станция	$12 000–25 000	€13 000–27 000	1,8–3,5 млн ₽	ограничено; аналоги — Huawei Ascend	₹12–25 лаккхов
Серверная стойка	$250–400 тыс.	€260–420 тыс.	40–70 млн ₽ (параллельный импорт)	Ascend 910C или H20 — экспортные ограничения	₹2,2–3,5 крора

Как считались цены. Это рыночные ориентиры на 26.10.2026 по розничным трекерам (Pangoly, Micro Center, eBay, vramglass, buildmypconline, ground.news) с поправками: в Германии +12–20 % (НДС 19 %, дефицит), в России +30–60 % (параллельный импорт и курс), в Китае действуют ограничения экспорта NVIDIA (продаются версии 5090D и H20, есть местные Ascend), в Индии +20–35 % (пошлины, налог GST 18 %). Курс: $1 ≈ 80–95 ₽, ¥7,2, ₹84, €0,92. Проверяйте цены перед покупкой: RTX 5090 за месяц подорожала с $4 200 до $6 000+.

Как покупать в России

1. **Где покупать.** Крупные сети и маркетплейсы (DNS, Ситилинк, Ozon, Яндекс Маркет и другие) во всех городах-миллионниках и большинстве городов от 500 тыс. жителей; редкие видеокарты и серверное оборудование — у интеграторов и под заказ.
2. **Гарантия.** Многие видеокарты и компьютеры Apple ввозятся по параллельному импорту: гарантию даёт магазин, а не производитель. Уточняйте срок и условия до покупки, храните чек.
3. **Цены.** В России те же модели обычно стоят на 30–60% дороже, чем в США, и сильно колеблются — сравните несколько магазинов и маркетплейсов.
4. **Для компаний.** Покупка через юрлицо с НДС; оборудование ставится на баланс и списывается за 3–5 лет. Для серверов в ЦОДе — договор колокации или аренды.

Сколько стоит электричество. Считайте так: мощность (кВт) × часы работы × тариф. Пример: ПК с видеокартой под нагрузкой потребляет около 0,5 кВт; 8 часов в день × 22 рабочих дня = 88 кВт·ч в месяц. При тарифе 8 ₽ за кВт·ч (условный пример — тарифы

различаются по регионам и типу дома) это около 700 ₽ в месяц. Ноутбук и Mac потребляют в разы меньше.

Как прикинуть, сколько памяти нужно модели

Простое правило: память для модели ≈ число параметров (в миллиардах) × разрядность сжатия ÷ 8, плюс 20–30 % на контекст и программу. Пример: модель 32B в 4-bit — 32 × 4 ÷ 8 = 16 ГБ, с запасом около 20 ГБ: помещается в видеокарту на 24 ГБ. Модель 70B в 4-bit — около 35 ГБ, с запасом 42–45 ГБ: нужна карта на 48 ГБ и больше или Mac с памятью от 64 ГБ.

Размер модели	Память в 4-bit	Память в 8-bit	Что подойдёт
7–8B	5–6 ГБ	9–10 ГБ	Ноутбук с 16 ГБ памяти
14B	8–10 ГБ	15–18 ГБ	Ноутбук или ПК с 24–32 ГБ
30–32B	18–20 ГБ	33–38 ГБ	RTX 4090 или 5090; Mac с 48–64 ГБ
70B	40–45 ГБ	75–85 ГБ	RTX PRO 6000 (96 ГБ); Mac с 96–128 ГБ
235B MoE (Qwen3 235B)	около 142 ГБ (файл в Ollama)	—	Mac Studio с 256 ГБ

Аренда вместо покупки: облако и дата-центры

Если ИИ нужен время от времени, выгоднее не покупать оборудование, а арендовать вычислительную мощность по часам или месяцам.

Вариант	Цена (октябрь 2026)	Когда выгодно	Что с приватностью
Аренда ускорителя H100 80 ГБ по часам, мировой рынок	Медиана $3,39–4,74 за час работы ускорителя; индекс Silicon Data $2,53–2,89; на «спот-рынке» (свободные мощности со скидкой) — от $1,49; у крупнейших облаков — $6,88–12,29	Разовые пиковые нагрузки, эксперименты, если оборудование было бы загружено меньше чем на 40 %	Данные лежат в ЦОД провайдера: выбирайте страну размещения и шифруйте диски
Россия: Selectel	Ускоритель L4 — от $0,87 в час; RTX PRO 6000 Blackwell — от $3,60; H200 — от $8,38	Нужно соблюдать 152-ФЗ, платить в рублях, заключать договор с юрлицом	ЦОД в России; действует российское законодательство о хранении данных
Россия: Yandex Cloud, Cloud.ru, VK Cloud	Серверы с видеокартами и готовые модели «под ключ» (например, GigaChat-3-Pro: 73 ₽ за 1 млн токенов на входе и 176 ₽ — на выходе)	Нужны готовые русскоязычные модели без своего оборудования	Размещение в России
Выделенный сервер с видеокартой (Россия или ЕС)	От 60–150 тыс. ₽ в месяц за 1–2 видеокарты	Постоянная нагрузка круглосуточно; нужен контроль над системой	Свой диск и ключи шифрования, но у провайдера есть физический доступ к серверу

Вариант	Цена (октябрь 2026)	Когда выгодно	Что с приватностью
Колокация своего сервера	20–60 тыс. ₽ в месяц за место в стойке плюс электричество	У вас уже есть оборудование, нужны надёжное питание и интернет	Максимум контроля при чужом питании и охлаждении

Цены Selectel в рублях (с НДС 22 %, selectel.ru, 10.11.2026): облачный сервер с L4 24 ГБ — от 69,88 ₽ в час, с RTX PRO 6000 96 ГБ — от 290,15 ₽ в час; выделенный сервер на месяц — от 56 900 ₽ (RTX 4090), 58 500 ₽ (L4) и 225 000 ₽ (RTX PRO 6000).

1. **8 часов в день, 22 дня (176 часов).** L4 — около 12 300 ₽, RTX PRO 6000 — около 51 000 ₽ в месяц: почасовая аренда примерно вчетверо дешевле выделенного сервера.
2. **Круглосуточно (730 часов).** L4 — около 51 000 ₽, RTX PRO 6000 — около 212 000 ₽: почти как выделенный сервер. При постоянной нагрузке берите выделенный.
3. **Покупка.** Рабочая станция с RTX PRO 6000 за 1,8–3,5 млн ₽ окупается против выделенного сервера за 225 000 ₽ примерно за 8–16 месяцев (без учёта электричества и обслуживания).
4. **Не забывайте про почасовой сервер.** Удаляйте его после пилота или эксперимента — иначе счёт продолжает расти.

Как быстро устаревает оборудование

Что оцениваем	Факты	Что это значит для планирования
Сколько видеокарта физически проработает	Исследование лаборатории ORNL: больше 95 % видеокарт работают через 3 года и больше 90 % — через 6 лет при хорошем охлаждении; при умеренной нагрузке — 5 лет и больше	Оборудование не «сгорает за 2 года»; главное — охлаждение и питание
Через сколько выгоднее купить новое	2–4 года: NVIDIA выпускает новое поколение каждые 1–2 года, и оно в 1,5–3 раза производительнее на каждый ватт	Через 3 года старое оборудование работает, но обходится дороже нового
Бухгалтерский срок списания	Крупные облачные компании списывают оборудование за 5–6 лет (CoreWeave — 6, Microsoft — 2–6, Amazon сократил до 5)	В России для бизнеса — 3–5 лет по классификатору ОКОФ; уточните у бухгалтера
Гарантия	Обычно 3 года; производитель может продлить	Для важных систем гарантия — фактически предел срока службы
Сколько дешевеют видеокарты	Обычно около 30 % в год для обычных ПК и до 60 % в год для топовых карт; 2026 год — исключение: цены растут из-за дефицита памяти	Покупайте под задачу, а не «на вырост»; рынок подержанных карт активен
Mac с общей памятью	Ценность держится за счёт большого объёма памяти: версию с 512 ГБ сняли с продажи, и подержанные стоят в 2–3 раза дороже исходной цены	Mac Studio легко перепродать

Как продлить срок службы и когда менять

1. **Охлаждение.** Следите за температурой видеокарты под нагрузкой программой мониторинга, чистите компьютер от пыли раз в 6–12 месяцев; сервер ставьте в помещение с кондиционером.

2. **Питание.** Блок питания — с запасом мощности 20–30 %, для сервера отдела — источник бесперебойного питания (ИБП): скачки напряжения опаснее нагрузки.
3. **Сначала — новая модель, потом — новое железо.** Новые версии моделей часто умнее при том же размере. Если отделу не хватает качества, сначала попробуйте свежую модель на том же оборудовании.
4. **Когда пора менять.** Нужная модель не помещается в память; ответы пишутся медленнее, чем сотрудники читают (меньше 10–15 т/с); гарантия закончилась, а простой системы обходится дорого.
5. **Перепродажа.** Видеокарту выгоднее продать через 2–3 года, пока на неё есть спрос; Mac Studio держит цену лучше.

Готовый план для типичного случая

Исходная ситуация: есть ноутбук с чипом Apple (Apple Silicon), а времени на администрирование мало.

1. **Шаг 1 — бесплатно.** Установите Ollama или LM Studio на имеющийся ноутбук с чипом Apple и запустите модель Qwen3 размером 14–30B. Её хватит для личных, финансовых и юридических задач без интернета — данные не покинут компьютер.
2. **Шаг 2 — когда задач станет больше (350–550 тыс. ₽).** Купите Mac mini или Mac Studio M5 с памятью 64–128 ГБ как тихий домашний сервер и поставьте на него Open WebUI — удобный веб-интерфейс для моделей, которым можно пользоваться с других компьютеров вашей сети.
3. **Шаг 3 — для бизнес-клиентов.** Арендуйте у Selectel ускорители L4 или RTX PRO 6000 по часам под пилотные проекты — без покупки оборудования.
4. **Облачные сервисы** используйте только для публичных и учебных задач и отключите в настройках использование ваших данных для обучения моделей.

Внедрение в офисе на 10-30 человек: восемь недель

1. **Неделя 1 — задачи и данные.** Назначьте ответственного, соберите 10–15 типичных задач отдела и для каждой отметьте, какие в ней данные (таблица в разделе о данных).
2. **Неделя 2 — правила.** Запишите на одной странице, какие сервисы и для каких данных разрешены; согласуйте с юристом и специалистом по защите информации.
3. **Недели 3–4 — пилот на 3–5 сотрудниках.** Обезличенные задачи — в российском облачном сервисе; закрытые документы — на арендованном сервере с RTX PRO 6000 (около 51 000 ₽ в месяц при работе 8 часов в день) или на Mac с памятью от 64 ГБ.
4. **Недели 5–6 — замеры.** Сравните время на задачу до и после, посчитайте долю ответов, которые пришлось переделывать, соберите отзывы.
5. **Неделя 7 — решение.** Купить, арендовать или остаться на облаке — по расчёту из раздела «Как выбрать».
6. **Неделя 8 — запуск для всех.** Обучение на 1–2 часа, памятка на одну страницу, чат для вопросов и ответственный за обновления.

Бюджет пилота. Аренда сервера на 1–2 месяца (около 51–102 тыс. ₽) плюс облачный сервис для компании (от 600 ₽ в месяц) — примерно 50–105 тыс. ₽. Это в 15–30 раз меньше покупки рабочей станции, а решение принимается на реальных цифрах.

Частые вопросы

1. **Нужно ли мне что-то покупать, чтобы начать?** Нет. Начните с бесплатных российских сервисов для обезличенных задач и с локальной модели на имеющемся ноутбуке.
2. **Локальная модель хуже ChatGPT?** В сложных рассуждениях, работе с картинками и поиске по интернету — да, отстаёт на 6–12 месяцев. Для писем, пересказов и работы с документами — часто достаточно.
3. **Можно ли пользоваться ИИ на работе?** Зависит от правил компании. Без разрешения не отправляйте в облако данные клиентов и сотрудников.
4. **Что выбрать отделу из 5–20 человек?** Тихий сервер (Mac Studio или ПК с RTX 5090) в офисе с веб-интерфейсом Open WebUI или аренда сервера у российского облачного провайдера.
5. **Можно ли запустить модель без видеокарты?** Да, на процессоре работают модели 4–8B, но медленно — несколько слов в секунду. Для знакомства этого достаточно.
6. **Какая модель лучше понимает русский язык?** Хорошо работают GigaChat с открытыми весами и Qwen3. Проверьте 2–3 модели на своих текстах — разница заметна сразу.
7. **Можно ли дать локальной модели доступ к интернету?** Можно, например через поиск в Open WebUI, но тогда запросы уходят поисковику. Для конфиденциальных задач поиск выключайте.
8. **Кто отвечает, если ИИ ошибся в документе для клиента?** Сотрудник, который отправил документ, и компания. Поэтому в правилах должна быть проверка человеком.
9. **Что будет, если зарубежный сервис заблокирует аккаунт?** История диалогов и загруженные файлы могут пропасть. Храните важные результаты у себя.

Источники: economize.cloud (26.10.2026), silicondata.com H100 Index (26.10.2026), gpueconomy.com Selectel (25.10.2026), whitefiber.com (25.08.2026), datacenterknowledge.com (08.09.2026), CNBC (14.11.2025), CITP Princeton (15.10.2025), vramglass.com (26.10.2026), runaihome.com (15.09.2026), ground.news/gamegpu (25.10.2026), buildmypconline (05.2026), habr.com/cloud_ru (19.10.2026), gptmag.ru (05.2026). Надбавки по странам — оценочные. Сведения о России (09.11.2026): обзоры тарифов GigaChat и Yandex AI Studio, материалы о трансграничной передаче персональных данных. Дополнения (10.11.2026): тарифы GigaChat — developers.sber.ru (07.10.2026); цены Yandex AI Studio — aistudio.yandex.ru; стартовый грант — yandex.cloud; цены серверов с видеокартами — selectel.ru; размеры моделей — ollama.com; штрафы за утечки — ст. 13.11 КоАП (КонсультантПлюс). Расчёты стоимости в примерах — наши, по этим ценам.

СВЯЗЬ И НОВЫЕ МАТЕРИАЛЫ

Где искать новые материалы

Новые файлы, а также ссылки на сообщества во ВКонтакте, Telegram, Teletype и Boosty — и, возможно, на YouTube, VK Видео, Rutube, Stepik и Udemy — ищите по этим контактам.

TG
TELEGRAM
t.me/artur_khant

VK
ВКОНТАКТЕ
vk.ru/artur_khant

TT
TELETYPE
teletype.in/@artur_khant

IG
INSTAGRAM
instagram.com/artur_khant

GH
GITHUB
github.com/artur-khant

CV
САЙТ-РЕЗЮМЕ
arturishkildin.cv

Не нашли ссылку на хранилище файлов или нужный цифровой продукт?
Напишите мне в личные сообщения или просто наберите в поиске

АРТУР ХАНТ