Локальные vs централизованные ИИ-модели: оборудование, цены, устаревание

Россия · США · Китай · Индия · Германия · Актуально на 26.10.2026

1. Локальные vs централизованные ИИ-модели: сравнение по критериям

Критерий	Локальная модель (своё железо)	Централизованная (ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT)
Приватность	Данные не покидают устройство/периметр; защищает от провайдера, его сотрудников, законных запросов к провайдеру	Данные у провайдера; выдаются по законным запросам; срок хранения 24 ч – 5 лет в зависимости от сервиса и настроек
Качество	Open-weight 2026: Qwen3.x, DeepSeek V4, Llama 4, Gemma 3, GigaChat Lite — уровень облачных моделей 2024–2025; отставание 6–12 мес	Фронтир-модели; мультимодальность; поиск с цитатами; агенты и коннекторы
Стоимость	CapEx 150 тыс. – 2,5 млн ₽ + электричество 0,3–1,5 кВт; нулевая цена за токен	$20–200/мес подписка или $0,3–15 за 1 млн токенов; РФ: 0,2–2,7 ₽ за ответ бота
Доступность из РФ	Полная; санкционные ограничения на закупку GPU (параллельный импорт +30–60 %)	Западные — через посредников (риск бана); российские — напрямую
Устаревание	Железо: экономический цикл 2–4 года, физический 5–6+ лет; модели обновляются ежеквартально — бесплатно	Провайдер обновляет сам; зависимость от изменений тарифов и политик
Контроль	Полный: версии моделей, логи, офлайн-режим	Нулевой: модель, лимиты, политика хранения меняются без согласия пользователя
Порог входа	Нужны навыки: Ollama/LM Studio — 1 час; vLLM + Open WebUI на сервере — 1–2 дня	Регистрация — 5 минут
Риски	Кража устройства; ошибки конфигурации при открытии в интернет; ответственность за бэкапы	Утечки провайдера; блокировки; смена юрисдикции; prompt-injection через коннекторы

2. Какое оборудование нужно: уровни и ориентиры цен (октябрь 2026)

Уровень / задача	Конфигурация	Модели	Цена США	Германия	Россия	Китай	Индия
Личный, ноутбук	MacBook Pro M4/M5 Pro 48–64 ГБ или ПК с RTX 4090 24 ГБ	7–32B (4-bit), Qwen3 30B-A3B	$2 500–4 000	€2 800–4 500	350–550 тыс. ₽	¥18–3 0 тыс.	₹2,5–4 лакха
Личный/микробизнес, десктоп	RTX 5090 32 ГБ + 64–128 ГБ RAM; сборка $8,5–9 тыс.; одна карта $4 200–6 000+ (дефицит, скупка ИИ-фирмами)	до 70B (4-bit), MoE 100B+ с выгрузкой	$8 500–11 000	€9 000–12 000 (карта от €5 249)	1,0–1,4 млн ₽	¥60–9 0 тыс. (5090 D, ограничения экспорта)	₹8–11 лакхов
Малый бизнес, тихий сервер	Mac Studio M5 Ultra 256–512 ГБ ($5 499–9 499+); б/у M3 Ultra 512 ГБ $16,5–27,5 тыс. (снят с продажи 03.2026)	DeepSeek V4 Flash 284B 4-bit ≈ 85 т/с; 300B-класс MoE	$9 500–12 000	€10 000–13 000	1,3–1,8 млн ₽	¥80–1 00 тыс.	₹10–13 лакхов
Малый/средний, рабочая станция	RTX PRO 6000 Blackwell 96 ГБ ($8 299) ×1–2 или DGX Spark 128 ГБ (~$4 000–4 700)	70–120B (8-bit), RAG на отдел	$12 000–25 000	€13 000–27 000	1,8–3,5 млн ₽	ограничено; аналоги Huawei Ascend	₹12–25 лакхов

Уровень / задача	Конфигурация	Модели	Цена США	Германия	Россия	Китай	Индия
Средний/крупный, стойка	Сервер 4–8× H100/H200/B200 или аренда	405B+, несколько моделей, 100+ пользов ателей	$250–400 тыс. (8×H100)	€260–420 тыс.	40–70 млн ₽ (параллельный импорт)	Ascend 910C / H20-ограничения	₹2,2–3,5 крора

Цены — рыночные ориентиры на 26.10.2026 по розничным трекерам (Pangoly, Micro Center, eBay, vramglass, buildmypconline, ground.news) с поправками: Германия +12–20 % (НДС 19 %, дефицит), Россия +30–60 % (параллельный импорт, курс), Китай — ограничения экспорта NVIDIA (варианты 5090D/H20, локальные Ascend), Индия +20–35 % (пошлины, GST 18 %). Курс: $1 ≈ 80–95 ₽, ¥7,2, ₹84, €0,92. Проверяй перед покупкой — RTX 5090 за месяц выросла с $4 200 до $6 000+.

3. Аренда вместо покупки: GPU-облако и дата-центры

Вариант	Цена (октябрь 2026)	Когда выгодно	Приватность
H100 80 ГБ, on-demand, мировой рынок	Медиана $3,39–4,74/GPU-час; индекс Silicon Data $2,53–2,89; спот от $1,49; гиперскейлеры $6,88–12,29	Пиковые нагрузки, эксперименты, <40 % загрузки	Данные в ЦОД провайдера; выбирать юрисдикцию; шифровать диски
Россия: Selectel	L4 от $0,87/час; RTX PRO 6000 Blackwell от $3,60; H200 от $8,38	152-ФЗ, рубли, договор с юрлицом	ЦОД в РФ; подпадает под российское законодательство о хранении
Россия: Yandex Cloud / Cloud.ru / VK Cloud	GPU-инстансы и managed-модели (Evolution Foundation Models: GigaChat-3-Pro 73/176 ₽ за 1 млн токенов вход/выход)	Готовые RU-модели без своего железа	Хостинг в РФ
Dedicated-сервер с GPU (RU/EU)	от 60–150 тыс. ₽/мес за 1–2 GPU	Постоянная нагрузка 24/7, нужен контроль ОС	Свой диск и ключи; провайдер — физический доступ
Colocation своего сервера	20–60 тыс. ₽/мес за юнит + электричество	Купленное железо + надёжное питание/канал	Максимум контроля при внешнем питании

4. Устаревание и износ оборудования

Параметр	Данные	Вывод для планирования
Физический срок службы GPU	Исследование ORNL: >95 % GPU живы через 3 года, >90 % через 6 лет при хорошем охлаждении; инференс при умеренной загрузке — 5+ лет	Железо не «сгорает за 2 года»; критичны охлаждение и питание
Экономический срок	2–4 года по каденции NVIDIA (новое поколение каждые 1–2 года даёт 1,5–3× производительности на ватт)	Через 3 года железо работает, но дороже в эксплуатации, чем новое
Бухгалтерская амортизация	Гиперскейлеры 5–6 лет (CoreWeave 6, Microsoft 2–6, Amazon снизил до 5)	Для бизнеса в РФ — 3–5 лет по ОКОФ, согласовать с бухгалтером
Гарантия	Обычно 3 года, расширение у OEM	Гарантия — практический потолок для критичных систем
Потеря стоимости потребительских GPU	≈30 %/год для ПК, до 60 %/год для топ-карт в обычные годы; 2026 — аномалия: рост цен из-за дефицита памяти	Покупать под задачу, не «на вырост»; б/у рынок активен
Mac с unified memory	Ценность держится из-за объёма памяти (512 ГБ снято с продажи → б/у ×2–3 от MSRP)	Mac Studio — ликвидный актив при перепродаже

5. Рекомендация для типового случая (ноутбук Apple Silicon, ограниченное время на администрирование)

Шаг 1 (0 ₽): Ollama/LM Studio на имеющемся ноутбуке Apple Silicon — Qwen3 14–30B для личных, финансовых и юридических задач офлайн. Шаг 2 (при росте нагрузки, 350–550 тыс. ₽): Mac mini/Studio M5 с 64–128 ГБ как тихий домашний сервер + Open WebUI + Tailscale для доступа с телефона. Шаг 3 (бизнес-клиенты): аренда Selectel L4/RTX PRO 6000 почасово под пилоты, без CapEx. Облачные сервисы — только для публичных и учебных задач с отключённым обучением.

Источники: economize.cloud (26.10.2026), silicondata.com H100 Index (26.10.2026), gpueconomy.com Selectel (25.10.2026), whitefiber.com (25.08.2026), datacenterknowledge.com (08.09.2026), CNBC (14.11.2025), CITP Princeton (15.10.2025), vramglass.com (26.10.2026), runaihome.com (15.09.2026), ground.news/gamegpu (25.10.2026), buildmypconline (05.2026), habr.com/cloud_ru (19.10.2026), gptmag.ru (05.2026). Региональные надбавки — оценочные.

СВЯЗЬ И НОВЫЕ МАТЕРИАЛЫ

Где искать новые материалы

Новые файлы, а также ссылки на сообщества во ВКонтакте, Telegram, Teletype и Boosty — и, возможно, на YouTube, VK Видео, Rutube, Stepik и Udemy — ищите по этим контактам.

TELEGRAM	t.me/artur_khant
ВКОНТАКТЕ	vk.ru/artur_khant
TELETYPE	teletype.in/@artur_khant
INSTAGRAM	instagram.com/artur_khant
GITHUB	github.com/artur-khant
САЙТ-РЕЗЮМЕ	arturishkildin.cv

Не нашли ссылку на хранилище файлов или нужный цифровой продукт? Напишите мне в личные сообщения или просто наберите в поиске **АРТУР ХАНТ**.