Свой ИИ на компьютере или облачный сервис: что выбрать и во что это обойдётся

Сравнение для России, США, Китая, Индии и Германии · цены и данные актуальны на 26.10.2026

Этот справочник помогает решить, где запускать ИИ для работы: на своём компьютере или в облачном сервисе вроде ChatGPT. Сначала – словарик и четыре вопроса для выбора, затем сравнение по восьми признакам, какое оборудование нужно и сколько оно стоит в пяти странах, когда выгоднее аренда, как быстро устаревает техника и готовый план для типичного случая.

Словарик: термины простыми словами

Облачная (централизованная) модель
ИИ, который работает на серверах компании: ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT. Вы пишете вопрос на сайте или в приложении, а ответ считается у них.

Локальная модель
ИИ, который вы скачиваете и запускаете на своём компьютере или сервере. Интернет для работы не нужен, данные никуда не уходят.

Открытые веса (open-weight)
модели, которые разработчики разрешают скачать: Qwen, DeepSeek, Llama, Gemma, GigaChat Lite.

B (миллиарды параметров)
размер модели: 7B – 7 миллиардов «настроек». Чем больше, тем умнее модель и тем мощнее нужен компьютер.

4-bit, 8-bit
сжатие модели (квантование): 4-bit занимает примерно вчетверо меньше памяти, чем исходная модель, почти без потери качества.

MoE
модель «из экспертов»: в каждый момент работает только её часть, поэтому большая модель считает быстрее.

Видеокарта (GPU) и видеопамять
главная деталь для ИИ. Объём видеопамяти (24, 32, 96 ГБ) определяет, какого размера модель поместится. У Mac с чипом Apple память общая (unified memory) – её можно почти всю отдать модели.

Токен
кусочек текста примерно в 3-4 буквы. Облачные сервисы считают оплату в токенах.

т/с (токенов в секунду)
скорость, с которой модель пишет ответ. 85 т/с – быстрее, чем человек читает.

RAG
поиск по своим документам: модель отвечает, опираясь на ваши файлы.

CapEx
разовые затраты на покупку оборудования (в отличие от ежемесячной подписки).

Лакх и крор
индийские единицы счёта: 1 лакх = 100 000 рупий, 1 крор = 10 000 000 рупий.

ЦОД
центр обработки данных – здание с серверами провайдера.

Колокация (colocation)
вы ставите свой сервер в чужой ЦОД и платите за место, электричество и интернет.

Ollama, LM Studio, vLLM, Open WebUI
программы для запуска локальных моделей: первые две – для себя на компьютере, вторые – для сервера на команду.

📋 Как выбрать: четыре вопроса

1. **Насколько секретны данные?** Личные, финансовые, юридические и клиентские данные лучше обрабатывать локально – они не покинут ваш компьютер. Публичные и учебные задачи можно решать в облаке.
2. **Нужен ли самый умный ИИ?** Облачные модели сильнее на 6–12 месяцев и умеют искать в интернете с цитатами. Локальные модели 2026 года – на уровне облачных 2024–2025 годов: для большинства офисных задач этого достаточно.
3. **Сколько есть денег и как часто нужен ИИ?** Для старта ничего покупать не нужно: модель запускается на хорошем ноутбуке. Оборудование окупается при постоянной нагрузке; при редкой – дешевле аренда или подписка.
4. **Есть ли время на настройку?** Программы Ollama или LM Studio на ноутбуке ставятся за час. Сервер для команды (vLLM и Open WebUI) – за 1–2 дня и требует навыков.

1 Свой ИИ или облачный: сравнение по восьми признакам

Что сравниваем	Свой ИИ на компьютере	Облачный сервис (ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT)
🔐 Приватность	Данные не покидают ваше устройство или сеть компании. Защищает от провайдера, его сотрудников и от законных запросов к провайдеру.	Данные хранятся у провайдера и выдаются по законным запросам. Срок хранения – от 24 часов до 5 лет, в зависимости от сервиса и настроек.
🧠 Качество	Модели с открытыми весами 2026 года – Qwen3.x, DeepSeek V4, Llama 4, Gemma 3, GigaChat Lite – на уровне облачных моделей 2024–2025 годов; отставание 6–12 месяцев.	Самые сильные (фронтирные) модели; работают с картинками, звуком и файлами; ищут в интернете с цитатами; умеют действовать через коннекторы.
💰 Стоимость	Разовая покупка оборудования – от 150 тыс. до 2,5 млн ₽, плюс электричество 0,3–1,5 кВт. За каждый ответ платить не нужно.	Подписка $20–200 в месяц или $0,3–15 за 1 млн токенов. В России – 0,2–2,7 ₽ за ответ бота.
🌍 Доступность из России	Полная. Но видеокарты из-за санкций покупаются через параллельный импорт – на 30–60 % дороже.	Западные сервисы – только через посредников, есть риск блокировки аккаунта; российские – напрямую.
⏳ Устаревание	Оборудование экономически устаревает за 2–4 года, физически служит 5–6 лет и дольше. Новые версии моделей выходят примерно раз в квартал – бесплатно.	Провайдер обновляет всё сам, но вы зависите от его тарифов и правил.
🎛️ Контроль	Полный: вы выбираете версию модели, видите журналы работы, можете работать без интернета.	Нет: модель, лимиты и правила хранения данных меняются без вашего согласия.
🛠️ Порог входа	Нужны навыки: Ollama или LM Studio – около 1 часа; сервер с vLLM и Open WebUI – 1–2 дня.	Регистрация за 5 минут.

Что сравниваем	Свой ИИ на компьютере	Облачный сервис (ChatGPT, Claude, Gemini, Perplexity, GigaChat, YandexGPT)
⚠️ Риски	Кража устройства; ошибки настройки, если открыть доступ из интернета; резервные копии — ваша забота.	Утечки у провайдера; блокировки; смена юрисдикции; подложенные инструкции (prompt injection) через коннекторы.

2 Какое оборудование нужно и сколько оно стоит (октябрь 2026)

Чем больше задача и чем больше людей пользуются ИИ, тем мощнее нужно оборудование. Сначала — что купить на каждом уровне и какие модели оно потянет, затем — цены по странам.

Уровень	Что купить	Какие модели потянет	Цена в США
👤 Для себя — ноутбук	MacBook Pro M4 или M5 Pro с памятью 48–64 ГБ или ПК с видеокартой RTX 4090 (24 ГБ)	Модели 7–32B в сжатии 4-bit, например Qwen3 30B-A3B	$2 500–4 000
🏠 Для себя или микробизнеса — настольный ПК	Видеокарта RTX 5090 (32 ГБ) и 64–128 ГБ оперативной памяти; сборка $8,5–9 тыс.; одна карта — $4 200–6 000+ (дефицит: их скупают ИИ-компании)	До 70B в сжатии 4-bit; модели MoE на 100B+ — с частичной выгрузкой в обычную память	$8 500–11 000
🏢 Малый бизнес — тихий сервер	Mac Studio M5 Ultra с памятью 256–512 ГБ ($5 499–9 499+); подержанный M3 Ultra 512 ГБ — $16,5–27,5 тыс. (снят с продажи в марте 2026)	DeepSeek V4 Flash 284B в 4-bit — около 85 токенов в секунду; модели MoE класса 300B	$9 500–12 000
🏭 Малый и средний бизнес — рабочая станция	Видеокарта RTX PRO 6000 Blackwell 96 ГБ ($8 299), одна или две, или компьютер DGX Spark 128 ГБ (около $4 000–4 700)	Модели 70–120B в сжатии 8-bit; поиск по документам отдела (RAG)	$12 000–25 000
🏗️ Средний и крупный бизнес — серверная стойка	Сервер с 4–8 ускорителями H100, H200 или B200 — или аренда	Модели 405B и больше, несколько моделей сразу, 100+ пользователей	$250–400 тыс. (8 × H100)

Уровень	США	Германия	Россия	Китай	Индия
Ноутбук	$2 500–4 000	€2 800–4 500	350–550 тыс. ₽	¥18–30 тыс.	₹2,5–4 лакха
Настольный ПК	$8 500–11 000	€9 000–12 000 (карта — от €5 249)	1,0–1,4 млн ₽	¥60–90 тыс. (модель 5090D, ограничения экспорта)	₹8–11 лакхов
Тихий сервер	$9 500–12 000	€10 000–13 000	1,3–1,8 млн ₽	¥80–100 тыс.	₹10–13 лакхов
Рабочая станция	$12 000–25 000	€13 000–27 000	1,8–3,5 млн ₽	ограничено; аналоги — Huawei Ascend	₹12–25 лакхов
Серверная стойка	$250–400 тыс.	€260–420 тыс.	40–70 млн ₽ (параллельный импорт)	Ascend 910C или H20 — экспортные ограничения	₹2,2–3,5 крора

Как считались цены. Это рыночные ориентиры на 26.10.2026 по розничным трекерам (Pangoly, Micro Center, eBay, vramglass, buildmypconline, ground.news) с поправками: в Германии +12–20 % (НДС 19 %, дефицит), в России +30–60 % (параллельный импорт и курс), в Китае действуют ограничения экспорта NVIDIA (продаются версии 5090D и H20, есть местные Ascend), в Индии +20–35 %

(пошлины, налог GST 18 %). Курс: $1 ≈ 80–95 ₽, ¥7,2, ₹84, €0,92. Проверяйте цены перед покупкой: RTX 5090 за месяц подорожала с $4 200 до $6 000+.

3 Аренда вместо покупки: облако и дата-центры

Если ИИ нужен время от времени, выгоднее не покупать оборудование, а арендовать вычислительную мощность по часам или месяцам.

Вариант	Цена (октябрь 2026)	Когда выгодно	Что с приватностью
☁️ Аренда ускорителя H100 80 ГБ по часам, мировой рынок	Медиана $3,39–4,74 за час работы ускорителя; индекс Silicon Data $2,53–2,89; на «спот-рынке» (свободные мощности со скидкой) – от $1,49; у крупнейших облаков – $6,88–12,29	Разовые пиковые нагрузки, эксперименты, если оборудование было бы загружено меньше чем на 40 %	Данные лежат в ЦОД провайдера: выбирайте страну размещения и шифруйте диски
Россия: Selectel	Ускоритель L4 – от $0,87 в час; RTX PRO 6000 Blackwell – от $3,60; H200 – от $8,38	Нужно соблюдать 152-ФЗ, платить в рублях, заключать договор с юрлицом	ЦОД в России; действует российское законодательство о хранении данных
Россия: Yandex Cloud, Cloud.ru, VK Cloud	Серверы с видеокартами и готовые модели «под ключ» (например, GigaChat-3-Pro: 73 ₽ за 1 млн токенов на входе и 176 ₽ – на выходе)	Нужны готовые русскоязычные модели без своего оборудования	Размещение в России
🖥️ Выделенный сервер с видеокартой (Россия или ЕС)	От 60–150 тыс. ₽ в месяц за 1–2 видеокарты	Постоянная нагрузка круглосуточно; нужен контроль над системой	Свой диск и ключи шифрования, но у провайдера есть физический доступ к серверу
🏢 Колокация своего сервера	20–60 тыс. ₽ в месяц за место в стойке плюс электричество	У вас уже есть оборудование, нужны надёжное питание и интернет	Максимум контроля при чужом питании и охлаждении

4 Как быстро устаревает оборудование

Что оцениваем	Факты	Что это значит для планирования
Сколько видеокарта физически проработает	Исследование лаборатории ORNL: больше 95 % видеокарт работают через 3 года и больше 90 % – через 6 лет при хорошем охлаждении; при умеренной нагрузке – 5 лет и больше	Оборудование не «сгорает за 2 года»; главное – охлаждение и питание
Через сколько выгоднее купить новое	2–4 года: NVIDIA выпускает новое поколение каждые 1–2 года, и оно в 1,5–3 раза производительнее на каждый ватт	Через 3 года старое оборудование работает, но обходится дороже нового
Бухгалтерский срок списания	Крупные облачные компании списывают оборудование за 5–6 лет (CoreWeave – 6, Microsoft – 2–6, Amazon сократил до 5)	В России для бизнеса – 3–5 лет по классификатору ОКОФ; уточните у бухгалтера
Гарантия	Обычно 3 года; производитель может продлить	Для важных систем гарантия – фактически предел срока службы

Что оцениваем	Факты	Что это значит для планирования
Сколько дешевеют видеокарты	Обычно около 30 % в год для обычных ПК и до 60 % в год для топовых карт; 2026 год – исключение: цены растут из-за дефицита памяти	Покупайте под задачу, а не «на вырост»; рынок подержанных карт активен
Mac с общей памятью	Ценность держится за счёт большого объёма памяти: версию с 512 ГБ сняли с продажи, и подержанные стоят в 2–3 раза дороже исходной цены	Mac Studio легко перепродать

5 Готовый план для типичного случая

Исходная ситуация: есть ноутбук с чипом Apple (Apple Silicon), а времени на администрирование мало.

1. **Шаг 1 – бесплатно.** Установите Ollama или LM Studio на имеющийся ноутбук с чипом Apple и запустите модель Qwen3 размером 14–30B. Её хватит для личных, финансовых и юридических задач без интернета – данные не покинут компьютер.
2. **Шаг 2 – когда задач станет больше (350-550 тыс. ₽).** Купите Mac mini или Mac Studio M5 с памятью 64–128 ГБ как тихий домашний сервер, поставьте на него Open WebUI (удобный веб-интерфейс для моделей) и Tailscale – чтобы безопасно подключаться к серверу с телефона.
3. **Шаг 3 – для бизнес-клиентов.** Арендуйте у Selectel ускорители L4 или RTX PRO 6000 по часам под пилотные проекты – без покупки оборудования.
4. **Облачные сервисы** используйте только для публичных и учебных задач и отключите в настройках использование ваших данных для обучения моделей.

Источники: economize.cloud (26.10.2026), silicondata.com H100 Index (26.10.2026), gpueconomy.com Selectel (25.10.2026), whitefiber.com (25.08.2026), datacenterknowledge.com (08.09.2026), CNBC (14.11.2025), CITP Princeton (15.10.2025), vramglass.com (26.10.2026), runaihome.com (15.09.2026), ground.news/gamegpu (25.10.2026), buildmypconline (05.2026), habr.com/cloud_ru (19.10.2026), gptmag.ru (05.2026). Надбавки по странам – оценочные.

СВЯЗЬ И НОВЫЕ МАТЕРИАЛЫ

Где искать новые материалы

Новые файлы, а также ссылки на сообщества во ВКонтакте, Telegram, Teletype и Boosty — и, возможно, на YouTube, VK Видео, Rutube, Stepik и Udemy — ищите по этим контактам.

TG
TELEGRAM
t.me/artur_khant

VK
ВКОНТАКТЕ
vk.ru/artur_khant

TT
TELETYPE
teletype.in/@artur_khant

IG
INSTAGRAM
instagram.com/artur_khant

GH
GITHUB
github.com/artur-khant

CV
САЙТ-РЕЗЮМЕ
arturishkildin.cv

Не нашли ссылку на хранилище файлов или нужный цифровой продукт?
Напишите мне в личные сообщения или просто наберите в поиске

АРТУР ХАНТ